

Transparência ES Inteligente

Proposta técnica e plano de execução da POC

Turma: 2ESPK · **Empresa fictícia:** DataCidadã Tech · **Solução:** Transparência ES Inteligente

Integrantes: Gustavo Garcia Silva (RM562078) · Nicolas Gara (RM561461) · João Vitor Reis Silva (RM563115) · João Marcelo Diniz Vespa (RM564038) · Thiago Luza Alves (RM562219) · Matheus Antunes (RM561292)

Repositório: github.com/Nicolas-Santana-Gara/transparencia-es-inteligente

Apresentação: github.com/Nicolas-Santana-Gara/transparencia-es-inteligente/blob/main/docs/apresentacao.pdf

1. Público e problema

O público principal são cidadãos e jornalistas que querem entender as despesas do Espírito Santo sem manipular arquivos CSV grandes. O público secundário são pesquisadores e organizações de controle social, que precisam de dados estruturados e verificáveis.

O conjunto de despesas tem centenas de milhares de linhas e exige conhecimento técnico para ser lido. Perguntas simples ficam sem resposta acessível: quanto foi pago, em que meses os pagamentos se concentram, quais unidades recebem mais recursos e de qual registro saiu um número.

O problema que escolhemos é **transformar o conjunto de dados fornecido em uma exploração visual, em linguagem simples, em que todo indicador pode ser rastreado até o Documento e o Id do registro de origem.**

2. Duas perguntas e evidências

Base utilizada: os quatro arquivos ZIP de despesas de 2025 fornecidos na disciplina, com **586.208 registros** entre 02/01/2025 e 31/12/2025. Fonte: Governo do Estado do Espírito Santo, com o Dicionário de Dados v1.0. Campos usados: Data, ValorEmpenho, ValorLiquidado, ValorPago, ValorRap, Favorecido, UnidadeGestora, GrupoDespesa, ElementoDespesa, Ação, Modalidade, TipoLicitacao, Documento e Id.

O material fornecido é um recorte sistemático. Todos os totais abaixo se referem a esse conjunto e não devem ser lidos como o total executado pelo Estado.

Preparação dos dados. Os arquivos usam ponto e vírgula, UTF-8 com BOM e vírgula decimal. Os valores foram convertidos para número e as datas normalizadas. Nenhuma linha foi removida.

Verificação	Resultado	Decisão
Datas inválidas	0	Nada a tratar
Linhas integralmente duplicadas	0	Nada a tratar
ValorPago negativo	12.747 (2,2%)	Mantidos e sinalizados como possíveis estornos ou ajustes
ValorPago igual a zero	413.609 (70,6%)	Mantidos: o registro representa outra etapa da despesa
Orgao, Funcao e NumeroProcesso	100% em branco	Não inferimos; a ausência é informada ao usuário

Empenho, liquidação, pagamento e restos a pagar são etapas diferentes e ficam em colunas separadas. As duas perguntas usam apenas **ValorPago**, em reais.

Pergunta 1: em quais meses de 2025 o valor pago se concentra?

Importa porque o cidadão e o jornalista começam pela pergunta "quando o dinheiro saiu". Somamos ValorPago por mês, de janeiro a dezembro de 2025, sem filtros, sobre os 586.208 registros.

Indicador	Valor
Total pago no conjunto analisado	R\$ 11.275.208.229,53
Maior mês: dezembro	R\$ 1,72 bilhão, 151,9% acima de novembro
Menor mês: julho	R\$ 354.079.113,76 (3,1% do total)
Média mensal	R\$ 939,6 milhões; dezembro foi cerca de 1,8 vez a média

Interpretação. O pico de dezembro é compatível com o encerramento do exercício orçamentário, folha e transferências programadas. Um pico não prova desperdício nem irregularidade.

Decisão de produto. A tela inicial abre com a série mensal de ValorPago, marca automaticamente o maior e o menor mês e explica o pico em texto junto ao gráfico. A aba "Quando se paga" compara o pagamento médio do mês de pico com o dos demais meses, com intervalo de confiança de 95%.

Pergunta 2: quais unidades gestoras e grupos de despesa concentram os pagamentos?

Importa porque indica onde olhar primeiro. Somamos ValorPago por UnidadeGestora e por GrupoDespesa, no ano de 2025, sem filtros, e calculamos a participação de cada um no total.

Recorte	Participação no valor pago	Valor
Fundo Estadual de Saúde (maior unidade gestora)	16,7%	R\$ 1.888.502.579,81
5 maiores unidades gestoras	52,7%	
10 maiores unidades gestoras	72,1%	
Grupo Pessoal e Encargos Sociais	45,1%	R\$ 5.080.984.159,25
Grupo Outras Despesas Correntes	34,1%	R\$ 3.849.733.086,55

Interpretação. Poucas unidades respondem pela maior parte do valor: dez delas somam quase três quartos. Pessoal e despesas correntes juntos passam de 79%.

Decisão de produto. O painel traz o ranking das 10 maiores unidades gestoras com valor e participação, a distribuição por grupo de despesa e a tabela dos registros de maior valor com Documento e Id.

Intervalo de confiança: quantos registros são de fato pagamento?

A maior parte das linhas não tem valor pago. Como o conjunto é um recorte, calculamos o intervalo de confiança de 95% dessas proporções, com $p \pm 1,96 \times \sqrt{(p(1-p)/n)}$ e $n = 586.208$.

Proporção de registros	Registros	Estimativa	IC 95%
ValorPago igual a zero	413.609	70,56%	70,44% a 70,67%
ValorPago negativo	12.747	2,17%	2,14% a 2,21%

Interpretação. Os intervalos são estreitos porque n é grande: cerca de 7 em cada 10 registros não representam pagamento, e isso não é efeito de poucos casos.

Decisão de produto. O painel não conta registro como pagamento. O indicador de volume é separado do valor pago, e o painel de qualidade informa quantos registros têm valor zero ou negativo, explicando que zero indica outra etapa da despesa e negativo indica possível estorno.

Limitações e vieses

- O conjunto é um recorte sistemático, não uma amostra aleatória. O intervalo de confiança vale como referência e os totais não representam o Estado.
- Orgao e Funcao vêm em branco, então não foi possível analisar por órgão ou função. Usamos unidade gestora e grupo de despesa.
- Só há dados de 2025. Não dá para dizer se o pico de dezembro se repete em outros anos.
- Pagamentos negativos reduzem os totais mensais e não foram classificados automaticamente.

3. Proposta de valor

A Transparência ES Inteligente entrega ao cidadão e ao jornalista a resposta já acompanhada da sua origem, sem planilha.

- **Menos esforço:** picos de pagamento e concentrações aparecem na primeira tela, sem abrir o CSV.
- **Sem caixa-preta:** cada indicador é explicado e leva ao Documento e ao Id do registro.
- **Limitações à mostra:** campos ausentes e valores negativos são informados, não escondidos.
- **Uso responsável:** o painel separa "registro atípico para revisão" de "irregularidade" e nunca rotula fraude.

4. Descrição e arquitetura da POC

A POC é uma aplicação web em **Streamlit**, com Python, pandas, Plotly e pytest. É a tecnologia recomendada no enunciado, toda de código aberto e sem credenciais externas.

Arquitetura: ZIPs oficiais → ETL (`src/etl.py`) → arquivos processados em `data_processed/` (Parquet e JSON) → aplicação (`app.py`) → usuário. Separar o processamento da tela faz o painel abrir rápido e permite que qualquer avaliador refaça o processamento.

Jornada demonstrada: o usuário abre o painel e vê os indicadores de 2025; identifica dezembro como pico na série mensal; compara as maiores unidades gestoras; filtra por mês, unidade gestora ou grupo de despesa; busca por favorecido, unidade, documento ou modalidade; e confere o Documento e o Id dos registros que formam o resultado.

ID	Funcionalidade pronta hoje	Como verificar
F01	Carregar os resultados processados de 2025	Indicadores abrem sem reprocessar os ZIPs
F02	Evolução mensal do valor pago	Gráfico com os 12 meses e marcação do pico
F03	Ranking de unidades gestoras	10 maiores por ValorPago, com percentual
F04	Distribuição por grupo de despesa	Todos os grupos com valor e participação
F05	Busca textual em registros	Filtra por favorecido, unidade, documento e modalidade
F06	Rastreabilidade	Tabela mantém Documento e Id em todo resultado
F07	Painel de qualidade dos dados	Mostra inválidos, duplicados e pagamentos negativos
F08	Reprocessamento dos ZIPs por linha de comando	O ETL para com mensagem clara se não achar nenhum ZIP

Situação de erro tratada: sem os ZIPs na pasta, o ETL interrompe e diz o que falta, em vez de gerar resultado vazio. Sem os ZIPs, o painel abre em modo demonstração, com dados simulados e um aviso em todas as telas de que não são os oficiais.

Repositório: `src/etl.py`, `data_processed/`, `app.py`, `tests/` (31 testes automáticos do ETL, das contas e do painel) e `README.md` com instalação, execução, limitações e origem dos dados.

Ainda não existe: dados de 2024, API de consulta, banco de dados, alertas e login. Tudo isso está no cronograma da seção 7.

5. Plano de dados

- **Hoje:** o ETL lê os quatro ZIPs de 2025, converte valores e datas, grava os registros tratados e o relatório de qualidade, e o painel abre a partir deles. Qualquer pessoa com os ZIPs refaz o processamento por linha de comando.
- **Depois:** inclusão de 2024, carga em banco de dados colunar e conferência automática dos totais por mês contra o arquivo original a cada carga.
- **Medidas:** ValorEmpenho, ValorLiquidado, ValorPago e ValorRap ficam separados e nunca são somados entre si.
- **Campos ausentes:** Orgao, Funcao e NumeroProcesso não são preenchidos por inferência. Se passarem a vir preenchidos, entram como novos filtros.
- **Privacidade:** a interface não destaca CPF ou CNPJ; a rastreabilidade usa Documento e Id. Os campos usados não incluem dados bancários e o repositório não guarda credenciais.

6. Equipe e responsabilidades

Seis integrantes. As horas são a dedicação de cada um em 4 meses, tomando 160 horas mensais como dedicação integral.

Integrante	Função principal	Atividades	Dedicação	Entregável sob sua responsabilidade
Gustavo Garcia	Engenharia de dados e back-end	Leitura dos ZIPs, conversão, agregação e integração	80% (512 h)	ETL reproduzível e arquivos processados
Nicolas Gara	Front-end e UX	Telas em Streamlit, gráficos e jornada do usuário	70% (448 h)	Painel com a jornada completa
João Vitor	Back-end júnior	Consultas, busca textual e correções	60% (384 h)	Busca e tabela de rastreabilidade por Documento e Id
João Vespa	Arquitetura de software	Arquitetura, revisão técnica e desempenho	45% (288 h)	Documento de arquitetura e revisão de todo pull request
Thiago Luza	Análise de dados	Indicadores, intervalo de confiança e registros atípicos	55% (352 h)	As duas análises e o painel de qualidade
Matheus Antunes	DevOps e testes	Testes, empacotamento, publicação e segurança	45% (288 h)	Suíte de testes, README e ambiente publicado

Como as partes se conectam. A análise (Thiago) define os indicadores a partir das duas perguntas. O ETL (Gustavo) entrega os dados que esses indicadores precisam. Front-end e back-end (Nicolas e João Vitor) levam cada indicador para a tela com o caminho até o registro. Testes (Matheus) conferem os números antes de cada marco e a arquitetura (João Vespa) revisa toda mudança.

Gestão. Reunião semanal de 30 minutos, backlog priorizado por valor e risco, pull request com revisão por par e decisões de escopo registradas no repositório. Uma mudança só é dada como pronta se roda localmente, tem documentação atualizada e teste do fluxo afetado.

7. Cronograma (16 semanas)

A POC do CP2 já funciona com as funcionalidades F01 a F08. As etapas abaixo são a evolução a partir dela. Cada marco libera uma parcela do valor.

Etap	Semanas	Responsável	Depende de	Entregável	Critério de aceite
1. Descoberta	1 a 2	Nicolas Gara e Thiago Luza	POC do CP2	Teste da POC com usuários e perguntas refinadas	5 pessoas do público usam a POC e o escopo é aprovado pela equipe
2. Planejamento (Marco 1, 15%)	3 a 4	João Vespa	Etap	Arquitetura alvo, backlog e plano de dados	Documentos revisados e backlog priorizado no repositório
3. Engenharia de dados (Marco 2, 20%)	5 a 7	Gustavo Garcia	Etap	ETL com 2024 e 2025 em banco de dados	Totais mensais iguais aos dos arquivos originais, sem ajuste manual
4. Desenvolvimento (Marco 3, 20%)	8 a 11	Nicolas Gara e João Vitor	Etap	Versão alfa com comparação entre 2024 e 2025 e alertas configuráveis	Usuário filtra, compara 2024 com 2025 e chega ao Documento e Id
5. Integração (Marco 4, 25%)	12 a 13	João Vespa e Gustavo Garcia	Etap	Versão beta com API de consulta	Consultas respondem em até 3 segundos
6. Validação e implantação (Marco 5, 20%)	14 a 16	Matheus Antunes	Etap	Sistema publicado, testado e documentado	Testes passando, ambiente no ar e 5 usuários completam a jornada sem ajuda

Se algo atrasar

- **Dado:** se os arquivos de 2024 não chegarem ou vierem em outro formato, a etapa 3 segue só com 2025 e a comparação entre anos sai da etapa 4.
- **Integração:** se a API atrasar, o painel continua lendo os arquivos processados, como na POC, e a API vira evolução.
- **Hospedagem:** se o ambiente publicado ficar instável, a entrega é feita com execução local documentada no README.

8. Orçamento

O total é de **R\$ 146.600,00**, abaixo do teto de R\$ 180.000,00, com margem de R\$ 33.400,00. Os salários são referências fictícias para a simulação; o valor por hora é o salário mensal dividido por 160 horas.

Função (integrante)	Horas	Valor por hora (R\$)	Custo (R\$)
Engenharia de dados e back-end (Gustavo Garcia)	512	53,13	27.200,00
Front-end e UX (Nicolas Gara)	448	46,88	21.000,00
Back-end júnior (João Vitor)	384	28,13	10.800,00
Arquitetura de software (João Vespa)	288	78,13	22.500,00
Análise de dados (Thiago Luza)	352	55,00	19.360,00
DevOps e testes (Matheus Antunes)	288	48,75	14.040,00
Subtotal equipe	2.272		114.900,00

Item	Valor (R\$)
Equipe (6 integrantes, 4 meses)	114.900,00
Infraestrutura: hospedagem, monitoramento e armazenamento	7.200,00
Licenças e ferramentas	2.500,00
Encargos e administração	12.000,00
Contingência para riscos técnicos e implantação	10.000,00
Total da POC	146.600,00

Custo mensal de operação depois da entrega: R\$ 3.850,00, somando infraestrutura e manutenção, ou R\$ 46.200,00 em 12 meses. O valor por hora está arredondado para centavos; o custo usa o valor exato.

9. Riscos e limites

Risco	Impacto	Mitigação	Responsável
Campos relevantes ausentes ou com baixa qualidade (Orgao, Funcao, NumeroProcesso)	Alto: limita as análises possíveis	Trabalhar só com campos preenchidos, declarar a ausência ao usuário e monitorar no painel de qualidade	Gustavo Garcia
Usuário ler pico ou registro atípico como prova de irregularidade	Alto: conclusão errada publicada	Texto explicativo ao lado de cada indicador e rastreabilidade até o registro antes de qualquer conclusão	Thiago Luza
Mudança no formato dos arquivos oficiais	Alto: o ETL deixa de rodar	Teste de conversão, validação das colunas esperadas e mensagem clara de erro	Gustavo Garcia
Instabilidade no ambiente de hospedagem	Médio: demonstração indisponível	Contingência de R\$ 10.000,00 e execução local como alternativa	Matheus Antunes
Integrantes sobrecarregados com outras demandas	Médio: atraso nos marcos	Dedicações de 45% a 80%, revisão semanal e redução de escopo conforme a seção 7	João Vespa

O risco que mais ameaça o plano é o primeiro: a qualidade do dado não depende da equipe e define quais perguntas a solução consegue responder.

Limites da POC. Usa só 2025; não analisa por órgão ou função, que vêm em branco; mantém os dados em memória, sem banco de dados; e os totais valem para o recorte fornecido, não para o Estado.

Uso de IA. A solução não usa IA para classificar despesas nem para apontar fraude. Na elaboração, usamos um assistente de IA como apoio na escrita do código da POC, na revisão desta proposta e na montagem dos slides. A verificação foi feita com testes automáticos, que comparam as contas com valores calculados à mão, e refazendo as contas do orçamento.

Fontes: enunciado do CP2 (CPSI simulado); Dicionário de Dados do Governo do Estado do Espírito Santo v1.0; quatro arquivos de despesas de 2025 fornecidos para a atividade.